

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Центр дополнительного, дополнительного профессионального и
онлайн-образования «Пуск»

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ
направление «01.04.02 Прикладная математика
и информатика»
профиль подготовки «Науки о данных»

**АНАЛИЗ СХОДСТВА НАУЧНЫХ МАТЕМАТИЧЕСКИХ СТАТЕЙ
ПО ФОРМУЛАМ И ИХ КОНТЕКСТУ**

Студент 2 курса
Группа М08–401НД
Насибулин Алексей Алексеевич

Руководитель:
кандидат технических наук
_____ Атаева О.М.

Москва 2026

СОДЕРЖАНИЕ

Глава 1. ВВЕДЕНИЕ	3
Глава 2. Анализ источников	7
Глава 3. Существующие методики	9
Глава 4. Эксперименты	10
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	13

Глава 1. ВВЕДЕНИЕ

В настоящее время в академической среде актуальна проблема поиска похожих по содержанию математических статей. Так для поиска совпадающей текстовой информации используют различные системы проверки схожести научных статей. Они анализируют то, насколько похожи тексты различных научных публикаций, в том числе тексты статей по математике. В качестве примера одной из таких систем можно привести систему iThenticate, которая, как и другие подобные системы, активно развивается и совершенствуется. Однако в описываемых современных рекомендательных системах, анализирующих схожесть научных статей, присутствует проблема идентификации схожести научных публикаций по математике: системы неспособны корректно различать математические формулы (например, $y = a + bx^2$ и $y = a + bx - 1/2$ неразличимы для системы iThenticate) [2]. Из этого следует, что существующие методы оценки схожести научных статей, в том числе те методы, которые применяются в готовых системах, неэффективны для научных статей, содержащих большое количество математических формул, то есть, для статей по математике.

Актуальность. Существующие методы поиска информации недостаточно эффективны для обнаружения схожих научных статей по математике так как они содержат большое количество математических формул. И, на данный момент, оценка сходства научных материалов по математике с точки зрения совпадения или близости по содержанию формул в настоящее время всё ещё недостаточно исследована. То есть, не смотря на то, что эта проблема уже не раз поднималась в различных научных публикациях [2; 9; 10], до сих пор не существует ни одной поискового метода, достаточно хорошо анализирующего математические выражения.

Целью магистерской квалификационной работы является разработка метода оценки схожести математических текстов на основе математических формул, содержащихся в них, с учётом контекста из текста.

Как было сказано ранее, современные методы поиска похожих научных статей не анализируют сходство математических формул. Популярные подходы, основанные на анализе текста, включают сопоставление строк, при котором документы сравниваются на предмет совпадения текстов, или измерение сходства документов с помощью различных показателей сходства [9]. Однако, например, при анализе научной литературы на разных языках, нужно учитывать сложные особенности написания научных статей на этих языках и возможные несоответствия переводов этих текстов содержанию оригинальных статей.

Поэтому, исходя из цели и предметной области, **гипотеза** сформулирована следующим образом: применение алгоритмов машинного обучения для поиска схожих математических формул позволит достигнуть лучших показателей поиска по математическим статьям в сравнении с существующими технологиями поиска, так как математика является «универсальным языком», и поэтому формулы следует анализировать приоритетно по отношению к тексту. В случае анализа научных публикаций по математике важно то, что математические формулы потенциально представляют собой значительную часть научного вклада, поэтому их игнорирование значительно ограничивает обнаружение похожих материалов [10]. Такой подход потенциально возможно использовать для индексации статей по формулам и добавления в семантическую библиотеку по предметной области знаний [1; 3].

Достижение цели исследования предполагает анализ и использование существующих технологий распознавания текста (в том числе в виде формул), реализацию поиска и индексации материалов по математическим формулам с текстовым подкреплением. Были определены следующие **задачи** магистерской квалификационной работы:

- 1) анализ технологий распознавания текста и математических формул из PDF-файлов;
- 2) анализ технологий поиска математических формул;
- 3) поиск существующих методик поиска по формулам с учётом контекста и реализация алгоритма поиска формул из анализируемой работы с учётом контекста.

Методология исследования представлена сочетанием теоретических и экспериментальных методов. Теоретический метод включает в себя поиск научных публикаций с теорией по поиску математических формул, анализ проблем поиска по математическим текстам, анализ проблем распознавания текстов и формул и реализацией различных технологий, решающих проблемы выше. Этот метод использовался из-за того, что при выполнении работы требуются как анализ существующих методик, так и понимание сферы решаемой проблемы в рамках исследовательской работы. Следует отметить, что научных публикаций на русском языке по рассматриваемой предметной области практически нет, поэтому использовался преимущественно англоязычный материал. Практический метод включает в себя тестирование существующих технологий распознавания текста/формул и технологий поиска по тексту/формулам, а так же реализация собственного алгоритма поиска по математическим формулам с текстовым подкреплением. Такой метод применялся из-за необходимости как сравнения существующих методик, так и их анализа возможного использования в рамках исследовательской работы.

Работа носит теоретико-практический характер и ориентирована на то, чтобы продемонстрировать, что реализация приоритетного поиска по математическим формулам в научных публикациях более эффективна для поиска схожих научных статей по математике с большим количеством магистерских формул, чем уже существующие системы поиска по тексту. Это и составляет **научную новизну** данной научной работы.

Глава 2. Анализ источников

Для поиска по текстам, в том числе научным текстам по математике, используют различные методики поиска [19]. Разделить их можно следующим образом:

- 1) поиск по онтологиям с помощью LLM [7; 17];
- 2) поиск с помощью RAG-систем [6];
- 3) семантическая аннотация из PDF-файлов [15].

Так как в подавляющем большинстве случаев в релевантных статьях рассматривается генерация ответа на вопрос пользователя по математике, где часто используются RAG-системы или подобные им, такие статьи тоже учтены при анализе источников.

Перед тем, как рассмотрим поиск с помощью RAG-систем, определим, что такое RAG. RAG (Retrieval-augmented generation) - это подход, при котором используется база знаний, представленная векторной базой данных, при обращении к которой соответствующей модели транслятора (текст-векторы), происходит поиск похожих векторов, которые добавляются в контекст запроса к LLM-модели, что позволяет генерировать ответ с использованием данных, не хранящихся в модели [13].

Рассмотрим поиск с помощью RAG-систем. При анализе существующих систем были выявлены несколько алгоритмов, используемых для поиска данных, используемых при генерации ответа на математический вопрос:

- 1) Использование классического RAG [14];
- 2) Использование RAG с повторными обращениями [18];
- 3) Использование RAG с трансляцией запрос в LaTeX формулу [11];
- 4) Использование GraphRAG [6];
- 5) Индексация с помощью MiniLM (embedding) и поиск с помощью LLM [20].

Примечательно то, что в части работ дополнительно рассматривается доказательство ответов, что потенциально может быть полезно при производстве поиска математических статей. При этом, во всех работах рассматривается вопрос обработки данных, в том числе из формата PDF, и в каждой приведённой работе он решён по-разному, в зависимости от типа требуемых готовых данных.

Теперь рассмотрим подходы с использованием онтологий. Они разнятся как по используемым данным, так и по подходам. Существующие решения:

- 1) Автоматическое составление графа знаний с использованием LLM на основе текстового содержания [7; 16];
- 2) Использование LLM при поиске по онтологиям [17];
- 3) Автоматическое составление онтологий по ссылкам и математическим формулам с использованием поисковых движков [5].

Стоит заметить, что все приведённые решения используют уже готовые тексты, то есть не требующие конвертации из PDF-формата.

Глава 3. Существующие методики

<NOPE>

Глава 4. Эксперименты

Для реализации алгоритма однозначного формул и текста планируется использовать OCR-модель, в которую добавляется документ (изображение), а на выходе получается его текстовое представление. Далее из этого представления извлекаются формулы. Формулы передаются в RAG систему поиска Tangent-3. Далее, проходя по совпадениям, происходит проверка схожести контекста текстов анализируемой статьи и совпадения через GraphRAG[8]. Данные, требуемые для работы поиска, берутся из открытых источников.

Далее, при нахождении предполагаемых похожих материалов по формулам, производится сравнение текстов анализируемого и похожего материала по контексту. При их достаточной схожести (будет метрика).




Рисунок 1. Pipeline системы

Однако в современных алгоритмах распознавания текста из PDF-файлов есть проблема со структурой распознаваемого текста: большинство моделей работают с типовыми форматами текста, на которых они были обучены. Из-за это-

Программа	<i>Acc</i>	<i>F₁</i>
Adobe Extract	0.85	0.74
Apache Tika	0.55	0.52
CERMINE	0.89	0.85
GROBID	0.90	0.90
PyMuPDF	0.85	0.85
PyMuPDF	0.55	0.51
RefExtract	0.55	0.49
Science Parse	0.79	0.76

Таблица 1. Метрики распознавания OCR. [4]

го фактора извлечение текста из материала нестандартного формата (размеры страницы, расположение текста) извлечение информации становится невозможным [12].

Большинство таких рекомендательных систем до сих пор используют классические алгоритмы распознавания текста из изображения, которые значительно уступают новым алгоритмам, основанных на машинном обучении. Так, например, программы с использованием классический алгоритмов Apache Tika, PyMuPDF значительно уступают по точности алгоритмам CERMINE, PdfAct, которые используют машинное обучение [4]. Сравнение этих алгоритмов можно увидеть в таблице 1.

Источники данных:

- 1) Статьи с сайта arxiv.org (PDF, TEX форматы): arxiv.org
- 2) Набор отрытых источников (PDF и другие форматы): <https://github.com/amao0o0/awesome-AI-Math-Datasets>.
- 3) Приватный датасет с научными материалами в различных форматах (в

том числе PDF);

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Подходы к извлечению знаний в научных предметных областях / О. Атаева [и др.] // Информационные и математические технологии в науке и управлении № 3 (35). — Иркутск : ИСЭМ СО РАН, 2024. — С. 5—19.
2. Полянин А. Д., Шингарева И. К. Индекс подобия математических и других научных публикаций с уравнениями и формулами и проблема идентификации самоплагиата. Математическое моделирование и численные методы // № 2. — Москва : МГТУ им. Н. Э. Баумана, 2021. — С. 96—116.
3. Тучкова Н. П., Атаева О. М. Подходы к извлечению знаний в научных предметных областях // Информационные и математические технологии в науке и управлении № 2 (18). — Иркутск : ИСЭМ СО РАН, 2020. — С. 5—18.
4. A Benchmark of PDF Information Extraction Tools Using a Multi-task and Multi-domain Evaluation Framework for Academic Documents / N. Meuschke [и др.] // Information for a Better World: Normality, Virtuality, Physicality, Inclusivity. — Springer Nature Switzerland, 2023. — С. 383—405. — ISBN 9783031280320. — DOI: 10.1007/978-3-031-28032-0_31. — URL: http://dx.doi.org/10.1007/978-3-031-28032-0_31.
5. ARQMath Lab: An Incubator for Semantic Formula Search in zbMATH Open? / P. Scharpf [и др.]. — 2020. — arXiv: 2012.02413 [cs.DL]. — URL: <https://arxiv.org/abs/2012.02413>.
6. Comparing RAG and GraphRAG for Page-Level Retrieval Question Answering on Math Textbook / E. Chen [и др.]. — 2025. — arXiv: 2509.16780 [cs.IR]. — URL: <https://arxiv.org/abs/2509.16780>.

7. Feng X., Wu X., Meng H. Ontology-grounded Automatic Knowledge Graph Construction by LLM under Wikidata schema. — 2024. — arXiv: 2412.20942 [cs.AI]. — URL: <https://arxiv.org/abs/2412.20942>.
8. From Local to Global: A Graph RAG Approach to Query-Focused Summarization / D. Edge [и др.]. — 2025. — arXiv: 2404.16130 [cs.CL]. — URL: <https://arxiv.org/abs/2404.16130>.
9. Isele M.-R. Analyzing Similarity in Mathematical Content To Enhance the Detection of Academic Plagiarism. — 2018. — arXiv: 1801.08439 [cs.IR]. — URL: <https://arxiv.org/abs/1801.08439>.
10. Korukhova Y., Kriger K., Riazanova E. Information Retrieval for Texts with Formulas //. — 01.2022. — С. 350—362. — DOI: 10.20948/abrau-2022-7.
11. LemmaHead: RAG Assisted Proof Generation Using Large Language Models / T. Yang [и др.]. — 2025. — arXiv: 2501.15797 [cs.LG]. — URL: <https://arxiv.org/abs/2501.15797>.
12. Logics-Parsing Technical Report / X. Chen [и др.]. — 2025. — arXiv: 2509.19760 [cs.CV]. — URL: <https://arxiv.org/abs/2509.19760>.
13. Martineau K. What is retrieval-augmented generation? //. — URL: <https://research.ibm.com/blog/retrieval-augmented-generation-RAG>.
14. Mathematical Reasoning for Unmanned Aerial Vehicles: A RAG-Based Approach for Complex Arithmetic Reasoning / M. Azarafza [и др.]. — 2025. — arXiv: 2506.04998 [cs.AI]. — URL: <https://arxiv.org/abs/2506.04998>.
15. Nikolaev K. Web-based visualization of semantic annotation of mathematical PDF documents //. — URL: <https://damdid2023.hse.ru/mirror/pubs/share/867944227.pdf>.

16. Ontology Generation using Large Language Models / A. S. Lippolis [и др.]. — 2025. — arXiv: 2503.05388 [cs.AI]. — URL: <https://arxiv.org/abs/2503.05388>.
17. Ontology Matching with Large Language Models and Prioritized Depth-First Search / M. Taboada [и др.]. — 2025. — arXiv: 2501.11441 [cs.IR]. — URL: <https://arxiv.org/abs/2501.11441>.
18. Retrieval-Augmented Process Reward Model for Generalizable Mathematical Reasoning / J. Zhu [и др.]. — 2025. — arXiv: 2502.14361 [cs.AI]. — URL: <https://arxiv.org/abs/2502.14361>.
19. Zanibbi R., Mansouri B., Agarwal A. Mathematical Information Retrieval: Search and Question Answering. — 2025. — arXiv: 2408.11646 [cs.IR]. — URL: <https://arxiv.org/abs/2408.11646>.
20. Zhang J. Small Language Models Offer Significant Potential for Science Community. — 2025. — arXiv: 2510.18890 [cs.CL]. — URL: <https://arxiv.org/abs/2510.18890>.