

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Центр дополнительного, дополнительного профессионального и
онлайн-образования «Пуск»

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ
направление «01.04.02 Прикладная математика
и информатика»
профиль подготовки «Науки о данных»

Разработка метода оценки схожести
математических научных статей

Студент 2 курса
Группа М08–401НД
Насибулин Алексей Алексеевич

Руководитель:
кандидат технических наук
_____ Атаева О.М.

Москва 2026

СОДЕРЖАНИЕ

1. ВВЕДЕНИЕ	3
1.1. Актуальность исследования	3
1.2. Цель и задачи работы	4
1.3. Объект и предмет исследования	6
1.4. Методы исследования	6
2. ОБЗОР ЛИТЕРАТУРЫ И СУЩЕСТВУЮЩИХ МЕТОДОВ	9
2.1. Существующие методы	9
3. ХОД РАБОТЫ	13
3.1. Используемые технологии	13
3.2. Датасет	15
3.3. Разработка и тестирование алгоритма	15
4. ОПИСАНИЕ ДОСТИГНУТЫХ РЕЗУЛЬТАТОВ	19
4.1. Анализ результатов	19
5. Заключение	21
ИСТОЧНИКИ	22

1. ВВЕДЕНИЕ

В настоящее время остро стоит проблема поиска по научным статьям из-за роста объемов данных и стремительного увеличения сложности текстов в различных предметных областях, особенно в предметной области «математика». Эта проблема актуальна в том числе и для русскоязычных текстов. Классические алгоритмы лексического поиска по тексту (например, BM25), применяемые в большинстве рекомендательных системах, уступают алгоритмам семантического поиска с использованием large language model (Большая языковая модель, далее - LLM) (например, RAG с использованием Qwen3) [25]. Однако LLM-алгоритмы, как и классические, некорректно обрабатывают семантические значения математических формул, из-за чего в поисковой выдаче либо присутствуют некорректные совпадения формул по смыслу, либо отсутствуют похожие по смыслу формулы [2; 8; 11]. А отдельный поиск по формулам без использования текстового содержания, хоть и эффективен для поиска по математическим статьям (например, Approach0 [28] достигает метрики качества $nDCG' = 0,72$ на задаче поиска по формулам ARQMath-3), но всё ещё не задействует текстовые данные, использование которых может значительно улучшить поиск по статьям.

1.1. Актуальность исследования

Проблема оценки сходства научных материалов по математике с контекстным использованием формул, содержащихся в PDF-файлах, в настоящее время всё ещё недостаточно исследована. То есть, не смотря на то, что проблема оценки схожести научных статей по математике уже не раз поднималась в различных научных публикациях [2; 12; 14], и были разработаны различные системы гибридного поиска (например, MABOWDOR [21]), до сих пор не существует ни одного поискового метода, использующего математические формулы с тексто-

вым подкреплением, экспортированные из PDF-файлов.

Основной рассматриваемой **проблемой** является то, что зачастую математический текст рассматривается как обычный текст, хотя это, по сути, двуязычный документ, то есть естественный язык и язык формул, которые дополняют друг друга, и именно их сочетание выражает смысл, который вкладывал в статью автор.

Однако оценка сходства научных материалов по математике по смыслу с учётом формул, содержащихся в PDF-файлах вместе с текстом, в настоящее время всё ещё недостаточно исследована. Особенно это актуально для русскоязычных текстов. Поэтому демонстрация того, что разработанный метод семантического поиска схожих научных статей по математике, имеет преимущество над существующими методами поиска по текстам и формулам (раздельно или вместе), составляет **научную новизну** данной научной работы.

1.2. Цель и задачи работы

Перед описанием целей и задач исследования необходимо определить, что такое «семантический поиск по математическим статьям». Семантический поиск по математическим статьям — это не просто поиск совпадающих слов или формул, а попытка понять, какую математическую задачу решает автор в этой статье, и найти работы, где решается та же самая задача, даже если она сформулирована другими словами, в другой форме или через другие обозначения и формулы.

Целью магистерской квалификационной работы является разработка метода оценки схожести математических текстов на основе математических формул, содержащихся в них, с учётом их контекста.

Поэтому, исходя из цели и актуальности, **гипотеза** сформулирована следующим образом: раздельное использование алгоритмов, реализующих подходы

семантического поиска по текстам и формулам, имеет такие ограничения, как потеря контекста математических формул, извлечённых из текстов [25], или их некорректное распознавание [2]. Предлагается использование методологии гибридного поиска схожих математических текстов по текстам и формулам, которые в них содержатся, чтобы обойти данных ограничения. Для доказательства верности методологии предлагается создать алгоритм, реализующий *гибридный поиск по текстам и формулам, которые в них содержатся*. При этом тексты, по которым производится поиск, могут быть представлены в PDF-формате, в том числе в их графическом представлении.

При анализе научной литературы на разных языках, нужно учитывать сложные особенности написания научных статей на этих языках и возможные несоответствия переводов этих текстов содержанию оригинальных статей. В случае анализа научных публикаций по математике важно то, что математические формулы потенциально представляют собой значительную часть научного вклада, поэтому их игнорирование значительно ограничивает обнаружение похожих материалов [14]. Такой подход потенциально возможно использовать для индексации статей по формулам и добавления в семантическую библиотеку по предметной области знаний [1; 3].

Таким образом, **методология** основана на сочетании методов поиска по тексту и по формулам, чтобы находить совпадения не только по словам, но и по смыслу как текстов, так и формул.

Ожидаемым **результатом работы** является создание алгоритма, который можно использовать в реальных системах научного поиска и рекомендаций таких как, например, научные библиотеки. Потенциальной практической пользой предлагаемого решения является создание инструмента, который снимает часть когнитивной нагрузки и рутинной работы, связанной с чтением, сравнением и анализом научных публикаций. Такой инструмент будет особенно ценен при подготовке обзоров, экспертной оценке статей и навигации по большим мас-

сивам научных текстов, в том числе текстов по математике.

Достижение цели исследования предполагает анализ и использование существующих технологий распознавания текста (в том числе в виде формул), реализацию поиска и индексации материалов по математическим формулам с текстовым подкреплением. Были определены следующие **задачи** магистерской квалификационной работы:

- 1) анализ технологий распознавания текста и математических формул из PDF-файлов;
- 2) анализ технологий поиска математических формул;
- 3) анализ технологий семантического поиска;
- 4) анализ существующих методик поиска по формулам с учётом контекста
- 5) реализация алгоритма гибридного поиска по текстам и формулам, которые в них содержатся, применяемого на научных статьях по математике.

1.3. Объект и предмет исследования

Объектом исследования являются поисковые системы.

Предметом исследования является контекстное сравнение формул.

1.4. Методы исследования

Методология исследования представлена сочетанием теоретических и экспериментальных методов.

Теоретический анализ.

Исследование начинается с аналитического обзора существующих работ и технологий в области:

- 1) поиска по математическим формулам;

- 2) семантического поиска по математическим текстам;
- 3) распознавания текстов и формул из PDF-файлов;
- 4) гибридных алгоритмов поиска по математическим материалам.

Наиболее распространённые подходы поиска информации в математических текстах можно разделить следующим образом: поиск по семантическим аннотациям из PDF-файлов [31], поиск с помощью RAG-систем [5], поиск по онтологиям через граф знаний [10]. Эти подходы исследуются для получения информации о том, какие проблемы поиска по математическим текстам актуальны и какие методологии уже реализованы.

Для выбора технологий OCR используется анализ бенчмарков этих технологий (OmniDocBench [20]), а для выбора моделей для работы с embedding использовались такие статьи как [27]. Этот метод использовался из-за того, что при выполнении работы требуются как анализ существующих методик, так и понимание специфики решаемой проблемы в НИР.

Методология и разработка дизайна эксперимента

Этап 1. Формирование экспериментальной базы:

- 1) сборка датасета научных статей в PDF-формате на русском языке в графических и текстовых представлениях;
- 2) нахождение пар похожих документов для последующего использования в эксперименте.

Этап 2. Проектирование и реализация алгоритма поиска:

Разрабатывается прототип алгоритма гибридного поиска, включающий:

- 1) обработку входного PDF-документа (OCR);
- 2) извлечение формул и текстовых блоков (главы, значимые части текста);
- 3) извлечение информации для индексации из текстовых блоков;
- 4) векторизация формул с добавлением в БД вместе с привязкой к докумен-

там, то есть создание индекса;

- 5) поиск по индексу похожих документов.

Этап 3.

Оценка результата:

- 1) Тестирование работы алгоритма на датасете документов, то есть проведение эксперимента;
- 2) Оценка результатов работы алгоритма.

Этот метод использовался для проведения эксперимента с воспроизводимыми результатами.

Выводы

Практическая работа над исследованием включает несколько взаимосвязанных шагов:

- 1) В ходе работы осуществляется расширение используемого датасета и реализация алгоритма поиска по математическим формулам с учётом текстового контекста.
- 2) Далее проводится тестирование работы поисковой системы на корпусе русскоязычных научных текстов.
- 3) Корректировка и уточнение алгоритма по результатам предыдущего этапа.
- 4) По мере развития проекта увеличивается объём обрабатываемых документов и, соответственно, расширяется поисковый индекс.

Выбор такого поэтапного подхода обусловлен необходимостью не только сопоставить существующие методы, но и оценить его устойчивость и масштабируемость в условиях реального пополняемого корпуса научных текстов. Такой подход формирует основу для обоснованного выбора и настройки методов семантического анализа и поиска, ориентированных на специфику математических текстов в русскоязычных научных коллекциях.

2. ОБЗОР ЛИТЕРАТУРЫ И СУЩЕСТВУЮЩИХ МЕТОДОВ

2.1. Существующие методы

Для поиска по текстам, в том числе научным текстам по математике, используют различные подходы поиска информации [27]. Наиболее распространённые подходы поиска информации можно разделить следующим образом:

- 1) поиск по семантическим аннотациям из PDF-файлов [31];
- 2) поиск с помощью RAG-систем [5];
- 3) поиск по онтологиям через граф знаний [10].

Перед тем, как рассмотрим системы поиска определим, что такое Retrieval-Augmented Generation (Генерация, дополненная поиском, далее – RAG). RAG — это подход, при котором используется база знаний, представленная векторной базой данных, при обращении к которой соответствующей модели транслятора (текст-векторы), происходит поиск похожих векторов, которые добавляются в контекст запроса к LLM-модели, что позволяет генерировать ответ с использованием данных, не хранящихся в модели [16].

RAG системы разделяются на два типа: классический RAG, в котором используется поиск по векторной БД, и GraphRAG, использующий граф знаний вместо БД. Оба типа систем на этапе анализа текстов при поиске или индексации не используют специфичную обработку формул, интерпретируя их как обычный текст, из-за чего поиск по формулам по существу не работает: например, после индексации более 5000 статей математического содержания системы неспособны корректно различать формулы. Более того, из-за специфики хранения документов в RAG-системах, поиск по точным совпадениям формул из проиндексированных документов невозможен.

Наиболее распространённые подходы такого поиска информации по онто-

логиям можно выделить следующим образом:

- 1) Поиск по графу знаний, создаваемому с использованием LLM [10; 13; 22]. Из-за того, что при построении графа знаний используются запросы к LLM, онтология, содержащаяся в ответе от неё, может быть некорректной (например, может быть извлечена только часть нужной формулы), так как у LLM-моделей есть склонность к ошибкам при ответе на математические вопросы [27].
- 2) Поиск по базе знаний, состоящей из текстов в векторном представлении, полученном через эмбединги [18]. Этот подход используется при построении RAG-систем, и он не подразумевает специфичную обработку для формул, из-за чего на большом массиве данных поиск по формулам становится невозможным.

Что касается алгоритмов поиска по формулам, то их можно поделить на три типа по виду представления формул [27]:

- 1) Представление в виде дерева (SLT, OPT). Это наиболее распространённый вид представления формул. Примеры современных алгоритмов с его использованием: Approach0 [28], BERT (модель MathBERT [17]), Tangent-CFT [26]. Эти алгоритмы предназначены только для поиска по формулам в LaTeX-представлении, без контекста (текста), который может быть представлен вместе с формулой или вместо неё. [Примером использования алгоритма с таким представлением формул для поиска по русскоязычным текстам является работа \[30\], в которой используется Tangent-CFT для поиска по формулам.](#)
- 2) Представление в текстовом виде. Пример алгоритма, использующего такой вид представления формул: LCS [24]. В современных алгоритмах такой вид представления не используется, так как поиск «по формулам как по текстам» неэффективен из-за особенностей их представления [12], которые

невозможно учесть при использовании лексического поиска.

- 3) Представление в виде LEAN-кода. Пример алгоритма, производящего поиск формул такого представления – LeanSearch (существует ещё версия без LLM) [15]. Этот вид представления используется в рекомендательных системах для ответов на математические вопросы, зачастую с использованием LLM. **Использование такого представления ПОКА не рассматривается.**

Существуют ещё системы гибридного поиска, из которых SOTA решением для поиска по тек-стам с формулами является MABOWDOR [21]. Он использует комбинацию технологий: алгоритм по-иска по формулам на основе SLT-дерева Approach0 [28], собственную BERT-подобную модель Coso-MAE [21] для поиска по формулам и алгоритм лексического поиска по текстам BM25+ [27] для поиска по текстам. Данная система не адаптирована для использования с текстами на русском языке.

Заметим, что все приведённые примеры алгоритмов предполагают использование материалов в готовом текстовом виде с формулами в LaTeX-формате, и, соответственно, производят оценку качества работы алгоритмов на таких бенч-марках как ARQMATH [4], NTCIR-12 [19]. Так как в рамках данной работы рассматривается работа с текстами научных работ по математике, которые содержат формулы, необходимо учесть, что значительная часть хранимых работ представлены в виде изображений или PDF-файлов с представлением текстов в виде изображений. Поэтому для учёта данной особенности нужно использовать технологию распознавания текста из изображений/документов (OCR), чтобы гарантировать возможность работы разрабатываемого поискового алгоритма со статьями, представленными как в текстовом виде, так и в виде изображений, в том числе в PDF-файлах со специфичной кодировкой или нестандартным форматированием. **По этой же причине прямое сравнение результатов**

работы существующих алгоритмов поиска по формулам с результатами работы разрабатываемого алгоритма невозможно.

Таким образом, в рассмотренных работах либо не используется распознавание текстов и формул из изображения, либо не используется гибридный поиск. То есть использование *комбинации* распознавания PDF-файлов и гибридного поиска по математическим формулам с текстовым подкреплением в других работах не рассматривалось. Кроме того, рассмотренные методики поиска не подразумевают работу с русскоязычными текстами (исключение - [30]).

ВАЖНО: ОБЗОР БУДЕТ РАСШИРЯТЬСЯ ДАЛЕЕ

3. ХОД РАБОТЫ

3.1. Используемые технологии

В рамках данной работы для поиска по формулам будет использоваться embedding-модель MathBERT [17]. Она находит похожие формулы по семантике. Эта модель была обучена на учебниках по математике и на статьях по математике с сайта arxiv.org [17]. Особенность данной модели заключается в том, что она позволяет производить семантический поиск по формулам через их векторизацию и последующий поиск по расстоянию между ними (например, используя scann [9]) как в RAG-системах. Пример работы поиска по формулам на порядка 100 их экземплярах представлен на рис. 1. На рисунке видно, что похожие по смыслу формулы найдены.

```
display(formula_search("(f + g)^2"))
display(formula_search("(f + g)^2", 7))
```

```
[(np.float32(11.692168), '(a+b)^2'),
 (np.float32(9.676985), '(c+d)^2 = c^2 + 2cd + d^2'),
 (np.float32(9.512249), 'a^2 + b^2 = c^2'),
 (np.float32(9.372129), 'y = a(x - h)^2 + k'),
 (np.float32(8.635685), "\x0crac{d}{dx} [f(x) + g(x)] = f'(x) + g'(x)")]
```

Рисунок 1. Результат работы MathBERT

Дополнительно в рамках данной работы используется эмбединг-модель embeddinggemma-300m [7] для извлечения ключевых слов из текстов статей. Эта модель общего назначения, обученная для работы с мультязычными текстами и имеющая лучшие показатели качества в различных бенчмарках, чем у моделей bge-m3 и Qwen3Embedding 0.6B, при сниженном практически вдвое количестве параметров выдаёт более релевантные ключевые слова при их запросе, как показано на рис. 2 (моделям на вход подавалась аннотация статьи по семантическому поиску [29], дополнительный промпт не использован). Только

используемая модель embeddinggemma-300m экспортировала фразу “библиотека libmeta”.

	model_name	keywords
0	sci_rus_small	междисциплинарного журнала, другие журналы, исследуется тематическое, журнала предлагается, журнала тематического, междисциплинарным исследованиям, статьи журнала, онтология журнала, экспертам журнала, интегрируются семантическую
1	frida_model	междисциплинарного журнала, журнала тематического, семантическую библиотеку, семантической библиотеке, онтология журнала, предлагается систематизация, междисциплинарной предметной, статьи журнала, тематической рубрики, анализа тематики
2	embeddinggemma_model	междисциплинарного журнала, журнала тематического, междисциплинарным исследованиям, анализа тематики, междисциплинарной предметной, журналов относящихся, анализа контента, контенту журнала, библиотеке libmeta, многообразие междисциплинарного
3	bge_m3_model	междисциплинарного журнала, онтология журнала, междисциплинарным исследованиям, анализа тематики, исследуется тематическое, журнала тематического, тематического анализа, журнала интегрируются, журнала вырабатывается, междисциплинарной предметной
4	qwen3embedding_model	междисциплинарного журнала, знаний журнала, журнала тематического, тематического анализа, междисциплинарным исследованиям, анализа тематики, статьи журнала, тематической рубрики, онтология журнала, исследуется тематическое

Рисунок 2. Сравнение работы BERT-моделей

Для вторичной обработки слов и их сравнения используются библиотеки nltk и difflib. Первая библиотека позволяет производить лемматизацию слов, что необходимо для корректного сравнения ключевых слов из текстов статей на русском языке. Вторая библиотека позволяет производить сравнение строк по расстоянию редактирования Левенштейна, что позволяет уменьшить влияние ошибок распознавания текста на качество поиска. Пример работы комбинации этих библиотек представлен на рис. 3.

Так как в данной работе требуется использование технологии OCR, на основании анализа результатов работы бенчмарка OmniDocBench [20] была выбрана технология PaddleOCR [23]. Эта технология позволяет извлекать текст из изображений и PDF-файлов, сохраняя информацию о структуре документа, что позволяет свести представление документов к единому формату, которое необходимо для корректной работы системы поиска похожих работ. Кроме того, она позволяет экспортировать математические формулы в TeX-формат, что необходимо для последующего поиска по формулам. Пример работы PaddleOCR по

```
import difflib
from nltk.stem.snowball import SnowballStemmer
stemmer = SnowballStemmer("russian")

words1, words2 = ["примеры", "тестим", "машина", "обучение"], ["примеров", "тест", "машина", "обучаться"]
stem_words1, stem_words2 = [stemmer.stem(word) for word in words1], [stemmer.stem(word) for word in words2]
for word in stem_words1:
    print(f"Word: {word}, Closest: {difflib.get_close_matches(word, stem_words2, cutoff=0.7)}")
```

✓ 0.0s

Word: пример, Closest: ['примеров']
 Word: тест, Closest: ['тест']
 Word: машина, Closest: ['машина']
 Word: обучен, Closest: ['обуча']

Рисунок 3. Пример сравнения слов

извлечению формул и текста из PDF-файла представлен на рис. 4.

3.2. Датасет

В рамках данной работы в качестве корпуса научных статей по математике был использован датасет научных работ на русском языке по математике и физике, содержащих математические формулы. Данный датасет представляет собой сборник PDF-файлов. Всего в этом датасете порядка 5000 статей. Все статьи взяты из трудов журнала «Известия высших учебных заведений» с 1997 по 2007 годы (1136 статей) и из трудов журнала «Вестник ТГУ» (3892 статьи). Датасет содержит как вложенные в текст формулы (далее — inline-формулы), так и выделенные формулы (далее — outline-формулы).

3.3. Разработка и тестирование алгоритма

Схема работы алгоритма, реализующего поиск похожих статей, представлена на рис. 5.

На вход алгоритму подаётся PDF-файл любого типа (страницы с произвольным текстовым и графическим содержанием, в том числе допустимо представление текстов в виде картинок или сканов). Из текста экспортируются текст,




Рисунок 4. Результат работы PaddleOCR

формулы и картинки (в том числе графики и таблицы). Работа с картинками на данный момент в рамках описываемого алгоритма не производится.

Шаги работы алгоритма:

- 1) Обработка (анализ) документа. На этом этапе документ переводится в текстовое представление через PaddleOCR [23]), а затем выполняется перевод документа в объектное представление: текст документа разделяется на блоки (параграфы/значимые блоки текста и формулы), а в блоках текста производится экспорт ключевых слов через BERT-модель




Рисунок 5. Схема работы алгоритма

EmbeddingGemma [7]. Такой подход позволяет логически разделить документ на блоки, из которых возможно извлечь более точный контекст за счёт уменьшенного количества текста на каждое вхождение при поиске, в отличие от векторизации текста полностью, одним блоком. Пример обработки документа в случае индексации приведён на рис. 6.

- 2) Индексация. Производится embedding найденных LaTeX формул через BERT-модель MathBERT [17] в векторное представление с последующим добавлением в векторную базу данных scann [9] для последующего использования при выполнении поиска по документам. Каждая формула имеет ссылку на объект блока документа, в котором она содержится. Используются только outline-формулы, то есть формулы, выделенные из текста. При проведении эксперимента индекс состоял из 144018 формул. Построение индекса заняло около 17 минут на процессоре AMD Ryzen 7840H.
- 3) Поиск. Сначала производится семантический поиск схожих формул в векторной базе данных по формулам из анализируемого текста. Далее статьи,

найденные по ссылкам на объекты блоков документов из похожих формул, фильтруются по ключевым словам, то есть происходит лексический поиск по словам (см. рис. 5). Результатом будет являться список похожих статей, отсортированных по релевантности. Метрикой оценки схожести статей является коэффициент схожести найденных формул, а точнее — метрика расстояния между векторными представлениями формул.




Рисунок 6. Пример индексации документа

4. ОПИСАНИЕ ДОСТИГНУТЫХ РЕЗУЛЬТАТОВ

4.1. Анализ результатов

Обнаруженные проблемы при разработке и тестировании алгоритма:

- 1) PaddleOCR имеет редкие ошибки распознавания содержащихся внутри текста inline-формулы: часть из текста «переходит» в корпус формулы, а часть формул распознаётся как обычный текст, как показано на рис. 7. Для решения этой проблем нужно либо дообучение моделей распознавания, либо использование нормализации текстов. В качестве меры уменьшения последствий этой проблемы используется не точное сравнение ключевых слов, а расстояние редактирования между ними [6] (пример на рис. 3).
- 2) Использование всего текста документа без дробления на части для извлечения ключевых слов через BERT-модель неэффективно, в том числе из-за ложных срабатываний («функция для» и «утверждение символах» считаются ключевыми словами, а это — ошибка) и потери большей части информации. Поэтому документы делятся на блоки (главы) для сужения контекста, извлекаемого из текста, что позволяет модели более точно выделять релевантные ключевые слова, за счёт чего улучшается качество поиска.
- 3) Если в индексируемой статье не было найдено outline-формул, то эта статья не появится в поисковой выдаче. Для обхода этой проблемы была произведена попытка использования inline-формул: при их добавлении количество найденных статей увеличивается, но при этом нерелевантные статьи начинают считаться релевантными, из-за чего был оставлен поиск только по outline-формулам.

Из датасета порядка 5000 научных статей по математике на русском языке экспертом были отобраны 50 пар схожих по тематике статей. При тестировании

Выход 2. Работает бесконечно много циклов, каждый из которых либо ждет в (4), либо находится в (5), пройдя через (46).

Случай, когда $\mathcal{P}$ -стратегия находится под бесконечным выходом нескольких $\mathcal{N}$ -стратегий, никаких новых проблем не ставит. Подчеркнем, что вышеописанная стратегия взаимодействия $\mathcal{P}$ - и $\mathcal{N}$ -стратегий будет работать при условии, что каждый цикл $\mathcal{N}$ -стратегии нарушается нижеуказанными $\mathcal{P}$ -стратегиями не более одного раза. Реализация этой идеи будет описана в Полной конструкции.

Выход 2. Работает бесконечно много циклов, каждый из которых либо ждет в (4), либо находится в (5), пройдя через (46).

Случай, когда $\mathcal{P}$ -стратегия находится под бесконечным выходом нескольких $\mathcal{N}$ -стратегий, никаких новых проблем не ставит. Подчеркнем, что вышеописанная стратегия взаимодействия $\mathcal{P}$ - и $\mathcal{N}$ -стратегий будет работать при условии, что каждый цикл $\mathcal{N}$ -стратегии нарушается нижеуказанными $\mathcal{P}$ -стратегиями не более одного раза. Реализация этой идеи будет описана в Полной конструкции.

Рисунок 7. Пример проблемы OCR

на вход алгоритму подавался первый документ из пары для поиска похожих текстов. Если в топ-10 похожих документов содержался второй документ из пары, то поиск считался успешным. Чем больше корректных пар было найдено – тем лучше. Таким образом при тестировании 39 пар было успешно найдено алгоритмом (см. рис. 8), что показывает преимущество данного подхода поиска похожих документов над поиском по ключевым словам, при использовании которого было успешно найдено 19 пар, или над поиском через RAG систему, при использовании которого было успешно найдено 26 пар.

	document	correct_similar_documents	accuracy
0	15792.pdf	15588.pdf	1.000000
1	15352.pdf	18214.pdf, 16740.pdf, 12036.pdf, 11021.pdf, 13201.pdf	0.090909
2	collection-udk_517_04-10-2005.pdf	collection-udk_517_03-6-2002.pdf	0.166667
3	collection-udk_517_03-3-2002.pdf	collection-udk_517_06-8-2001.pdf, collection-udk_517_04-7-2003.pdf, collection-udk_517_10-8-2005.pdf	0.111111
4	collection-udk_517_04-7-1998.pdf	collection-udk_517_11-8-2003.pdf	0.125000
5	collection-udk_517_05-5-2003.pdf	collection-udk_515_01-7-1997.pdf, collection-udk_517_11-5-1998.pdf, collection-udk_517_05-1-2001.pdf	0.250000
6	15318.pdf	15320.pdf	1.000000
7	collection-udk_519_04-12-2004.pdf	collection-udk_519_10-12-2002.pdf	1.000000
8	19186.pdf	10962.pdf	0.200000
9	17270.pdf	16373.pdf	0.500000
10	collection-udk_517_05-5-1998.pdf	12998.pdf, collection-udk_517_10-7-2002.pdf	0.142857
11	15460.pdf	15555.pdf, collection-udk_517_10-1-2004.pdf, 17115.pdf, collection-udk_517_05-6-2000.pdf, collection-udk_519_06-6-2005.pdf	0.111111
12	14974.pdf	12384.pdf, 14971.pdf, 15906.pdf, 19381.pdf, 12287.pdf	0.076923
13	11603.pdf	14027.pdf	0.250000
14	collection-udk_517_13-2-1998.pdf	collection-udk_517_12-5-1998.pdf, collection-udk_517_07-2-2003.pdf, 17332.pdf, collection-udk_517_09-4-2001.pdf	0.111111

Рисунок 8. Результат работы алгоритма

5. Заключение

В данной работе получен основной результат: успешное нахождение похожих математических статей на тестируемом приватном датасете научных публикаций на русском языке с использованием алгоритма, основанном на поиске по формулам с текстовым подкреплением. Алгоритм решает проблему поиска похожих научных статей на русском языке, которые содержат математические формулы.

Хотя на данный момент алгоритм имеет множество проблем: отсутствие корректировки результатов распознавания текста, средний результат извлечения ключевых слов и отсутствие использования графа знаний, применяемого в библиотечных системах, он успешно находит похожие статьи в проиндексированных алгоритмом PDF-документах по документу, который подаётся на вход алгоритму.

Алгоритм, в отличие от его аналогов, позволяет производить поиск по текстам, не переведённым в текстовый формат. Он успешно находит похожие статьи в проиндексированных алгоритмом PDF-документах по документу, который подаётся на вход алгоритму. Перечисленные выводы служат отправными точками для дальнейших исследований по разработке алгоритма поиска похожих статей по математике в PDF-формате. Работа над улучшением работы алгоритма продолжается.

ИСТОЧНИКИ

1. Подходы к извлечению знаний в научных предметных областях / О. Атаева [и др.] // Информационные и математические технологии в науке и управлении № 3 (35). — Иркутск : ИСЭМ СО РАН, 2024. — С. 5—19.
2. Полянин А. Д., Шингарева И. К. Индекс подобия математических и других научных публикаций с уравнениями и формулами и проблема идентификации самоплагиата. Математическое моделирование и численные методы // № 2. — Москва : МГТУ им. Н. Э. Баумана, 2021. — С. 96—116.
3. Тучкова Н. П., Атаева О. М. Подходы к извлечению знаний в научных предметных областях // Информационные и математические технологии в науке и управлении № 2 (18). — Иркутск : ИСЭМ СО РАН, 2020. — С. 5—18.
4. ARQMath Lab: An Incubator for Semantic Formula Search in zbMATH Open? / P. Scharpf [и др.]. — 2020. — arXiv: 2012.02413 [cs.DL]. — URL: <https://arxiv.org/abs/2012.02413>.
5. Comparing RAG and GraphRAG for Page-Level Retrieval Question Answering on Math Textbook / E. Chen [и др.]. — 2025. — arXiv: 2509.16780 [cs.IR]. — URL: <https://arxiv.org/abs/2509.16780>.
6. Elmobark N. A Comparative Analysis of Python Text Matching Libraries: A Multilingual Evaluation of Capabilities, Performance and Resource Utilization // International Journal of Environment, Engineering and Education. — 2025. — Т. 7, № 1. — С. 48—60.
7. EmbeddingGemma: Powerful and Lightweight Text Representations / H. S. Vera [и др.]. — 2025. — arXiv: 2509.20354 [cs.CL]. — URL: <https://arxiv.org/abs/2509.20354>.

8. Evaluation of LLMs for mathematical problem solving / R. Wang [и др.]. — 2025. — arXiv: 2506.00309 [cs.AI]. — URL: <https://arxiv.org/abs/2506.00309>.
9. Fast and Scalable Gene Embedding Search: A Comparative Study of FAISS and ScaNN / M. S. Refahi [и др.]. — 2025. — arXiv: 2507.16978 [q-bio.GN]. — URL: <https://arxiv.org/abs/2507.16978>.
10. Feng X., Wu X., Meng H. Ontology-grounded Automatic Knowledge Graph Construction by LLM under Wikidata schema. — 2024. — arXiv: 2412.20942 [cs.AI]. — URL: <https://arxiv.org/abs/2412.20942>.
11. Forootani A. A Survey on Mathematical Reasoning and Optimization with Large Language Models. — 2025. — arXiv: 2503.17726 [cs.AI]. — URL: <https://arxiv.org/abs/2503.17726>.
12. Isele M.-R. Analyzing Similarity in Mathematical Content To Enhance the Detection of Academic Plagiarism. — 2018. — arXiv: 1801.08439 [cs.IR]. — URL: <https://arxiv.org/abs/1801.08439>.
13. Khasanshin A., Zaikin D., Zhiltsov N. Indexing mathematical scholarly papers as Linked Open Data // RuSSIR 2012. — 2012.
14. Korukhova Y., Kriger K., Riazanova E. Information Retrieval for Texts with Formulas //. — 01.2022.— С. 350—362. — DOI: 10.20948/abrau-2022-7.
15. Li I. R. Towards Lightweight and LLM-Free Semantic Search for mathlib4. —.
16. Martineau K. What is retrieval-augmented generation? //. — URL: <https://research.ibm.com/blog/retrieval-augmented-generation-RAG>.
17. MathBERT: A Pre-trained Language Model for General NLP Tasks in Mathematics Education / J. T. Shen [и др.]. — 2023. — arXiv: 2106.07340 [cs.CL]. — URL: <https://arxiv.org/abs/2106.07340>.

18. Neural relation extraction for knowledge base enrichment / B. Distiawan [и др.] // Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. — 2019. — С. 229—240.
19. NTCIR-12 MathIR Task Overview. / R. Zanibbi [и др.] // NTCIR. — 2016.
20. Omnidocbench: Benchmarking diverse pdf document parsing with comprehensive annotations / L. Ouyang [и др.] // Proceedings of the Computer Vision and Pattern Recognition Conference. — 2025. — С. 24838—24848.
21. One blade for one purpose: advancing math information retrieval using hybrid search / W. Zhong [и др.] // Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. — 2023. — С. 141—151.
22. Ontology Generation Using Large Language Models / A. S. Lippolis [и др.] // The Semantic Web / под ред. Е. Curry [и др.]. — Cham : Springer Nature Switzerland, 2025. — С. 321—341. — ISBN 978-3-031-94575-5.
23. PaddleOCR 3.0 Technical Report / C. Cui [и др.]. — 2025. — arXiv: 2507.05595 [cs.CV]. — URL: <https://arxiv.org/abs/2507.05595>.
24. Pavan Kumar P., Agarwal A., Bhagvati C. A structure based approach for mathematical expression retrieval // International workshop on multi-disciplinary trends in artificial intelligence. — Springer. 2012. — С. 23—34.
25. Stuhlmann L., Saxer M. A., Fürst J. Efficient and Reproducible Biomedical Question Answering Using Retrieval Augmented Generation // 2025 IEEE Swiss Conference on Data Science (SDS). — IEEE, 06.2025. — С. 154—157. — DOI: 10.1109/sds66131.2025.00029. — URL: <http://dx.doi.org/10.1109/SDS66131.2025.00029>.

26. Tangent-CFT: An embedding model for mathematical formulas / B. Mansouri [и др.] // Proceedings of the 2019 ACM SIGIR international conference on theory of information retrieval. — 2019. — С. 11—18.
27. Zanibbi R., Mansouri B., Agarwal A. Mathematical Information Retrieval: Search and Question Answering // Foundations and Trends in Information Retrieval. — 2025. — Янв. — Т. 19, № 1/2. — С. 1—190. — ISSN 1554-0669. — DOI: 10.1561/15000000095. — eprint: <https://www.emerald.com/ftinr/article-pdf/19/1-2/1/11139694/15000000095en.pdf>. — URL: <https://doi.org/10.1561/15000000095>.
28. Zhong W., Xie Y., Lin J. Applying Structural and Dense Semantic Matching for the ARQMath Lab 2022, CLEF. // CLEF (Working Notes). — 2022. — С. 147—170.
29. Интеллектуальный анализ данных при построении графа знаний мультидисциплинарного журнала / О. М. Атаева [и др.] // Информационные и математические технологии в науке и управлении. — 2024. — 3 (35). — С. 5—19.
30. Николаев К. С. Сервис семантического поиска формул по коллекции математических PDF-документов // Информационные технологии и вычислительные системы. — 2025. — № 3. — С. 34—43.
31. Николаев К. С. Учёт структуры документа в методе автоматического аннотирования математических понятий в образовательных текстах // Электронные библиотеки. — 2024. — Т. 27, № 4. — С. 558—577.