

ОТЧЕТ
о научно-исследовательской работе за 3 семестр 2025/2026 учебного года: исследование

ФИО студента Насибулин Алексей Алексеевич
Факультет, группа Центр дополнительного, дополнительного профессионального и онлайн-образования «Пуск», М08-401НД

Базовая организация, кафедра Центр дополнительного, дополнительного профессионального и онлайн-образования «Пуск»

Тема НИР Разработка метода оценки схожести математических научных статей

Текущее состояние НИР за семестр (проделанная работа и полученные результаты)

Общая информация об исследовании

1. *Тема исследования* - "Разработка метода оценки схожести математических научных статей".
2. *Объектом исследования* являются поисковые системы.
3. *Предметом исследования* является сравнение математических текстов вместе с формулами.
4. *Целью исследования* является разработка и тестирование алгоритма семантического поиска схожих научных статей по математике, использующего поиск по математическим формулам с текстовым подкреплением.
5. *Задачи исследования (кратко)*: анализ технологий распознавания текста (на русском и прочих языках) и математических формул из PDF-файлов, анализ технологий поиска по математическим формулам, анализ технологий семантического поиска по тексту, анализ существующих методик поиска по формулам с учётом контекста, реализация алгоритма поиска формул из научных работ по математике на русском языке с учётом их контекста.
6. *Проблема и исследовательский вопрос в основе исследования*. В настоящее время остро стоит проблема поиска по научным статьям из-за роста объемов данных и стремительного увеличения сложности текстов в различных предметных областях, особенно в предметной области "математика". Эта проблема актуальна в том числе и для русскоязычных текстов. Классические алгоритмы лексического поиска по тексту (например, BM25), применяемые в большинстве рекомендательных системах, уступают алгоритмам семантического поиска с использованием LLM (например, RAG с использованием Qwen3) [1]. Однако LLM-алгоритмы, как и классические, некорректно обрабатывают семантические значения математических формул, из-за чего в поисковой выдаче либо присутствуют некорректные совпадения формул по смыслу, либо отсутствуют похожие по смыслу формулы [2, 3, 4]. А отдельный семантический поиск по формулам без

использования текстового содержания, хоть и эффективен для поиска по математическим статьям (например, Approach0 [12] достигает метрики качества $nDCG' = 0,72$ на задаче поиска по формулам ARQMath-3), но всё ещё не задействует текстовые данные, использование которых может значительно улучшить поиск по статьям [5].

7. *Актуальность и новизна исследования.* Основной рассматриваемой проблемой является то, что зачастую математический текст рассматривается как обычный текст, хотя это, по сути, двуязычный документ, то есть естественный язык и язык формул, которые дополняют друг друга, и именно их сочетание выражает смысл, который вкладывал в статью автор. Однако оценка сходства научных материалов по математике по смыслу с учётом формул, содержащихся в PDF-файлах вместе с текстом, в настоящее время всё ещё недостаточно исследована. Особенно это актуально для русскоязычных текстов. Поэтому демонстрация того, что разработанный метод семантического поиска схожих научных статей по математике, имеет преимущество над существующими методами поиска по текстам и формулам (раздельно или вместе), составляет научную новизну данной научной работы.
8. *Гипотеза исследования.* Раздельное использование алгоритмов, реализующих подходы семантического поиска по текстам и формулам, имеет такие ограничения, как потеря контекста математических формул, извлечённых из текстов [1], или их некорректное распознавание [2]. Поэтому предлагается использование методологии гибридного поиска схожих математических текстов по текстам и формулам, которые в них содержатся, чтобы обойти данные ограничения. Для доказательства верности методологии предлагается создать алгоритм, реализующий гибридный поиск по текстам и формулам, которые в них содержатся. При этом тексты, по которым производится поиск, могут быть представлены в PDF-формате, в том числе в их графическом представлении.

Методология исследования и дизайн эксперимента

Перед описанием методологии исследования необходимо определить, что такое “семантический поиск по математическим статьям”.

Семантический поиск по математическим статьям — это не просто поиск совпадающих слов или формул, а попытка понять, какую математическую задачу решает автор в этой статье, и найти работы, где решается та же самая задача, даже если она сформулирована другими словами, в другой форме или через другие обозначения и формулы.

Теоретический анализ

Исследование начинается с аналитического обзора существующих работ и технологий в области:

- поиска по математическим формулам;
- семантического поиска по математическим текстам;
- распознавания текстов и формул из PDF-файлов;
- гибридных алгоритмов поиска по математическим материалам.

Наиболее распространённые подходы поиска информации в математических текстах можно разделить следующим образом: поиск по семантическим аннотациям из PDF-файлов [6], поиск с помощью RAG-систем [7], поиск по онтологиям через граф знаний [8]. Эти подходы исследуются для получения информации о том, какие проблемы поиска по математическим текстам актуальны и какие методологии уже реализованы.

Для выбора технологий OCR используется анализ бенчмарков этих технологий (OmniDocBench [21]), а для выбора моделей для работы с embedding использовались такие статьи как [5].

Этот метод использовался из-за того, что при выполнении работы требуются как анализ существующих методик, так и понимание специфики решаемой проблемы в НИР.

Методология и разработка дизайна эксперимента

Этап 1. Формирование экспериментальной базы:

- сборка датасета научных статей в PDF-формате на русском языке в графических и текстовых представлениях;
- нахождение пар похожих документов для последующего использования в эксперименте.

Этап 2. Проектирование и реализация алгоритма поиска: Разрабатывается прототип алгоритма гибридного поиска, включающий:

- обработку входного PDF-документа (OCR);
- извлечение формул и текстовых блоков (главы, значимые части текста)
- извлечение информации для индексации из текстовых блоков
- векторизация формул с добавлением в БД вместе с привязкой к документам, то есть создание индекса
- поиск по индексу похожих документов.

Этап 3. Оценка результата:

- Тестирование работы алгоритма на датасете документов, то есть проведение эксперимента
- Оценка результатов работы алгоритма

Этот метод использовался для проведения эксперимента с воспроизводимыми результатами.

Выводы

Практическая работа над исследованием включает несколько взаимосвязанных шагов:

- В ходе работы осуществляется расширение используемого датасета и реализация алгоритма поиска по математическим

формулам с учётом текстового контекста.

- Далее проводится тестирование работы поисковой системы на корпусе русскоязычных научных текстов.
- Корректировка и уточнение алгоритма по результатам предыдущего этапа.
- По мере развития проекта увеличивается объём обрабатываемых документов и, соответственно, расширяется поисковый индекс.

Выбор такого поэтапного подхода обусловлен необходимостью не только сопоставить существующие методы, но и оценить его устойчивость и масштабируемость в условиях реального пополняемого корпуса научных текстов. Такой подход формирует основу для обоснованного выбора и настройки методов семантического анализа и поиска, ориентированных на специфику математических текстов в русскоязычных научных коллекциях.

Результаты эксперимента

Разработка и тестирование алгоритма гибридного поиска проводились с использованием датасета русскоязычных научных статей в PDF-формате порядка 5000 штук. В текстах этого датасета содержались как вложенные в текст формулы (далее – inline-формулы), так и выделенные формулы (далее – outline-формулы).

Для поиска по формулам использовалась embedding-модель MathBERT [13]. Она находит похожие формулы по семантике. Эта модель обучена на учебниках по математике и на статьях по математике с сайта arXiv.org [13]. Особенность данной модели заключается в том, что она позволяет производить семантический поиск по формулам через их векторизацию и последующий поиск по расстоянию между ними (например, используя scann [24]) как в RAG-системах. Пример работы поиска по формулам на порядка 100 их экземплярах представлен на рис. 1. На рисунке видно, что похожие по смыслу формулы найдены, хоть и имеют разные обозначения переменных и разные формульные представления.

```
display(formula_search("(f + g)^2", 3))  
✓ 0.0s  
[(np.float32(11.692168), '(a+b)^2'),  
 (np.float32(9.676985), '(c+d)^2 = c^2 + 2cd + d^2'),  
 (np.float32(9.512249), 'a^2 + b^2 = c^2')]
```

Рис. 1. Результат работы MathBERT

Схема работы алгоритма, реализующего поиск похожих статей, представлена на рис. 3.




Рис. 3. Схема работы алгоритма

На вход алгоритму подаётся PDF-файл любого типа (страницы с произвольным текстовым и графическим содержанием, в том числе допустимо представление текстов в виде картинок или сканов). Из текста экспортируются текст, формулы и картинки (в том числе графики и таблицы). Работа с картинками на данный момент в рамках описываемого алгоритма не производится.

Шаги работы алгоритма:

1. Обработка (анализ) документа. На этом этапе документ переводится в текстовое представление через PaddleOCR, затем выполняется перевод документа в объектное представление: текст документа разделяется на блоки (параграфы/значимые блоки текста и формулы), а в блоках текста производится экспорт ключевых слов через BERT-модель EmbeddingGemma [22]. Такой подход позволяет логически разделить документ на блоки, из которых возможно извлечь более точный контекст за счёт уменьшенного количества текста на каждое вхождение при поиске, в отличие от векторизации текста полностью, одним блоком. Пример обработки документа в случае индексации приведён на рис. 6.
2. Индексация. Производится embedding найденных LaTeX формул через BERT-модель MathBERT [13] в векторное представление с последующим добавлением в векторную базу данных scann [24] для последующего использования при выполнении поиска по документам. Каждая формула имеет ссылку на объект блока документа, в котором она содержится. Используются только outline-формулы, то есть формулы, выделенные из текста. При проведении эксперимента индекс состоял из 144018 формул. Построение индекса заняло около 17 минут на процессоре AMD Ryzen

7840Н.

3. Поиск. Сначала производится семантический поиск схожих формул в векторной базе данных по формулам из анализируемого текста. Далее статьи, найденные по ссылкам на объекты блоков документов из похожих формул, фильтруются по ключевым словам, то есть происходит лексический поиск по словам (см. рис. 3). Результатом будет является список похожих статей, отсортированных по релевантности. Метрикой оценки схожести статей является коэффициент схожести найденных формул, а точнее – метрика расстояния между векторными представлениями формул.




Рис. 6. Пример индексации документа

document	correct_similar_documents	accuracy
0 15792.pdf	15588.pdf	1.0000
1 15352.pdf	18214.pdf, 16740.pdf, 12036.pdf, 11021.pdf, 13201.pdf	0.0909
2 collection-udk_517_04-10-2005.pdf	collection-udk_517_03-6-2002.pdf	0.1666
3 collection-udk_517_03-3-2002.pdf	collection-udk_517_06-8-2001.pdf, collection-udk_517_04-7-2003.pdf, collection-udk_517_10-8-2005.pdf	0.1111
4 collection-udk_517_04-7-1998.pdf	collection-udk_517_11-8-2003.pdf	0.1250
5 collection-udk_517_05-5-2003.pdf	collection-udk_515_01-7-1997.pdf, collection-udk_517_11-5-1998.pdf, collection-udk_517_05-1-2001.pdf	0.2500
6 15318.pdf	15320.pdf	1.0000
7 collection-udk_519_04-12-2004.pdf	collection-udk_519_10-12-2002.pdf	1.0000
8 19186.pdf	10962.pdf	0.2000
9 17270.pdf	16373.pdf	0.5000
10 collection-udk_517_05-5-1998.pdf	12998.pdf, collection-udk_517_10-7-2002.pdf	0.1428
11 15460.pdf	15555.pdf, collection-udk_517_10-1-2004.pdf, 17115.pdf, collection-udk_517_05-6-2000.pdf, collection-udk_519_06-6-2005.pdf	0.1111
12 14974.pdf	12384.pdf, 14971.pdf, 15906.pdf, 19381.pdf, 12287.pdf	0.0769
13 11603.pdf	14027.pdf	0.2500
14 collection-udk_517_13-2-1998.pdf	collection-udk_517_12-5-1998.pdf, collection-udk_517_07-2-2003.pdf, 17332.pdf, collection-udk_517_09-4-2001.pdf	0.1111

Рис. 7. Результат работы алгоритма

Таким образом был разработан и протестирован прототип алгоритма семантического поиска по формулам с текстовым подкреплением.

Выводы по результатам эксперимента

Предварительные выводы:

Алгоритм, в отличие от его аналогов, позволяет производить поиск по текстам, не переведённым в текстовый формат. Он успешно находит похожие статьи в проиндексированных алгоритмом PDF-документах по документу, который подаётся на вход алгоритму. Хотя созданный алгоритм нашёл схожие по смыслу математические формулы, при разработке и тестировании алгоритма были обнаружены некоторые проблемы:

1. PaddleOCR имеет редкие ошибки распознавания содержащихся внутри текста inline-формулы: часть из текста “переходит” в корпус формулы, а часть формул распознаётся как обычный текст, как показано на рис. 5. Для решения этой проблем нужно либо дообучение моделей распознавания, либо использование нормализации текстов. В качестве меры уменьшения последствий этой проблемы используется не точное сравнение ключевых слов, а расстояние редактирования между ними [25].
2. Использование всего текста документа без дробления на части для извлечения ключевых слов через BERT-модель неэффективно, в том числе из-за ложных срабатываний (“функция для” и “утверждение символов” считаются ключевыми словами, а это - ошибка) и потери большой части информации. Поэтому документы делятся на блоки (главы) для сужения контекста, извлекаемого из текста, что позволяет модели более точно выделять релевантные ключевые слова, за счёт чего улучшается качество поиска.
3. Если в индексируемой статье не было найдено outline-формулы, то эта статья не появится в поисковой выдаче. Для обхода этой проблемы была произведена попытка использования inline-формулы: при их добавлении количество найденных статей увеличивается, но при этом нерелевантные статьи начинают считаться релевантными, из-за чего был оставлен поиск только по outline-формулам.

Выход 2. Работает бесконечно много циклов, каждый из которых либо ждёт в (4), либо находится в (5), пройдя через (46).

Случай, когда P -стратегия находится под бесконечным выходом нескольких N -стратегий, никаких новых проблем не ставит. Подчеркнем, что вышеописанная стратегия взаимодействия P - и N -стратегий будет работать при условии, что каждый цикл N -стратегии нарушается нижними P -стратегиями не более одного раза. Реализация этой идеи будет описана в Полной конструкции.

Выход 2. Работает бесконечно много циклов, каждый из которых либо ждёт в (4), либо находится в (5), пройдя через (46).

Случай, когда P -стратегия находится под бесконечным выходом нескольких N -стратегий, никаких новых проблем не ставит. Подчеркнем, что вышеописанная стратегия взаимодействия P - и N -стратегий будет работать при условии, что каждый цикл N -стратегии нарушается нижними P -стратегиями не более одного раза. Реализация этой идеи будет описана в Полной конструкции.

Рис. 5. Пример проблемы OCR

Выбранные конференции или научные мероприятия для подачи заявки на участие

Всероссийская конференция “Актуальные проблемы семантического анализа данных”; 16–20 февраля 2026 г; ФИЦ ИУ РАН, Москва; <https://semantic-actual.ru/>; Анализ сходства научных математических статей по формулам и их контексту

Итоги НИР за семестр

Участие в акселераторах, хакатонах, дататонах, чемпионатах по тематике проекта (название, даты проведения, формат участия, сертификаты/победы)

- Принимал(а) участие
- Не принимал(а) участие

Участие в научных и бизнес-конференциях, других бизнес-мероприятиях (название, даты проведения, формат участия)

- Принимал(а) участие
- Не принимал(а) участие

Публикация в рекомендуемых научных изданиях (подтверждение публикации прикладывается к отчету)

- Принимал(а) участие
- Не принимал(а) участие

Участие в конкурсах на лучшую НИР и выставках (авторы, название работы и конкурса (экспоната и выставки))

- Принимал(а) участие
- Не принимал(а) участие

Медали, дипломы, грамоты, премии и т. п. на конкурсах на лучшую НИР и на выставках (авторы, название работы и конкурса (экспоната и выставки), вид награды)

- Принимал(а) участие
- **Не принимал(а) участие**

Проекты, поданные на конкурсы грантов (авторы, название и вид гранта)

- Принимал(а) участие
- **Не принимал(а) участие**

Полученные гранты (авторы, название и вид гранта)

- Принимал(а) участие
- **Не принимал(а) участие**

Другое (заявки и охранные документы на объекты интеллектуальной собственности, проданные лицензии на их использование, участие в инвест-сессиях и питчинг-сессиях, стипендии Президента и Правительства РФ и т. п.)

- Принимал(а) участие
- **Не принимал(а) участие**

Материальная поддержка НИР студента за семестр (с указанием источника финансирования)

- **Без поддержки**
- Поддержка:

Трудоустройство во время практики

- **нет**
- да, по срочному трудовому договору;
- да, по бессрочному трудовому договору;
- иное (стажировка и пр.).

Место прохождения стажировки/работы: -

План работы на следующий семестр

1. январь: расширение датасета PDF-файлов научных статей по математике *планируемый результат*: увеличение датасета до 10 000 статей (или больше)
2. февраль-март: решить проблемы распознавания документов, заменить лексический поиск, использовать сравнение значимых фрагментов текста *планируемый результат*: корректное распознавание данных из документов,

использование семантического поиска и сравнения по значимым фрагментам текста

3. апрель-май: проведение тестирования и сравнения с другими технологиями поиска (установка используемых метрик, тестирования других технологий **на русскоязычных текстах**), **подготовка текста диплома**, *планируемый результат*: составление полного анализа и сравнения технологий поиска по математическим формулам, **подготовленный текст диплома**

Отзыв научного руководителя

Заполняется научным руководителем

Содержательный и развернутый отзыв по работе студента в 3 семестре.

Детализация оценки НИР студента за 3 семестр

Заполняется научным руководителем

I. Оценка за отчет по НИР:

1. Наглядность и содержательность презентации: _____ баллов (максимум $10 * 0,1$).
2. Цель, актуальность, новизна, объект, предмет и проблема исследования: _____ баллов (максимум $10 * 0,1$).
3. Теоретический анализ проблемы: _____ баллов (максимум $10 * 0,1$).
4. Постановка гипотезы и задач, корректность выбранной методологии: _____ баллов (максимум $10 * 0,2$).
5. Эмпирические результаты исследования: _____ баллов (максимум $10 * 0,2$).
6. Структурированность диссертации и логика изложения глав ВКР: _____ баллов (максимум $10 * 0,1$).
7. Владение предметной областью и профессиональными навыками: _____ баллов (максимум $10 * 0,1$).
8. Подготовка результатов исследования к конференции / публикации: _____ (максимум $10 * 0,1$).

Оценка за отчет по НИР: _____ баллов (средняя оценок выше, максимум 10)

II. Оценка за промежуточные презентации по НИР: 5,40 баллов (максимум 10)

III. Оценка за НИР студента за 3 семестр: [Оценка за отчет по НИР] * 0,5 + [Оценка за промежуточные презентации по НИР] * 0,5

Оценка НИР студента за 3 семестр

Заполняется научным руководителем

Рекомендуемая оценка:

_____ баллов (по 10-балльной шкале)

К отчету прикреплены:

- **Презентация исследования** (Приложение)
https://docs.google.com/presentation/d/1wivxv5WYp8pZQVYwqhie3c0M9BeE_CS4/edit?usp=sharing&ouid=106931942648778517246&rtpof=true&sd=true
- **Первая глава диссертации и черновик второй** (полностью переделан)
<https://disk.360.yandex.ru/i/Y11dLooR-GjzYQ>
- Структура ВКР (с пояснениями) https://disk.360.yandex.ru/d/lfdln_kPaZc2ag
- **Собранные и описанные данные по эксперименту** (отдельным приложением к диссертации)
https://github.com/nasibulinaa/mipt_mag_diploma/blob/main/conference/rnd/work28.ipynb
- **Артефакты, созданные в рамках работы над исследованием за третий семестр**
https://github.com/nasibulinaa/mipt_mag_diploma
- (Если есть) Программа конференции, на которой выступали или будете выступать в рамках учебного года с темой на основе исследования. [ссылка](#)

Дата составления отчета – 09.12.25

Студент  /ФИО/Насибулин Алексей Алексеевич

Подпись

Научный руководитель _____ /ФИО/

Подпись

Зав. кафедрой _____ /ФИО/

Подпись